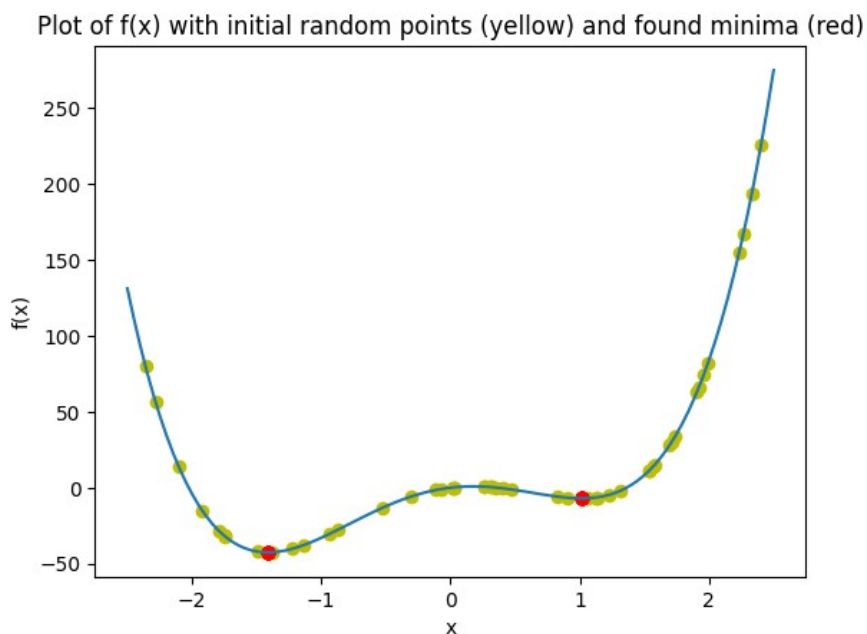


# WSI Ćwiczenie 1 - metoda gradientu prostego

Jakub Romankiewicz, 325063


Utworzono klasę GradientDescentSolver posiadającą funkcję solve() znajdującą minimum funkcji metodą gradientu prostego. Funkcja  $f(x)$  blisko siebie posiada minimum globalne oraz minimum lokalne, oba udało się odkryć stworzoną funkcją.



Rys. 1 – Poglądowy przebieg funkcji  $f(x)$  z zaznaczonymi losowymi punktami początkowymi algorytmu (żółte) i końcowymi punktami reprezentującymi znalezione minima funkcji (czerwone) .

Funkcja  $g(x_1, x_2)$  posiada jedno, bardzo płaskie minimum.

Plot of  $f(x)$  with initial random points (yellow) and found minima (red)



Rys. 2 – Poglądowy przebieg funkcji  $g(x_1, x_2)$  z zaznaczonymi losowymi punktami początkowymi algorytmu (żółte) i końcowymi punktami reprezentującymi znalezione minima funkcji (czerwone).

Algorytm zainicjalizowano z hiperparametrami:

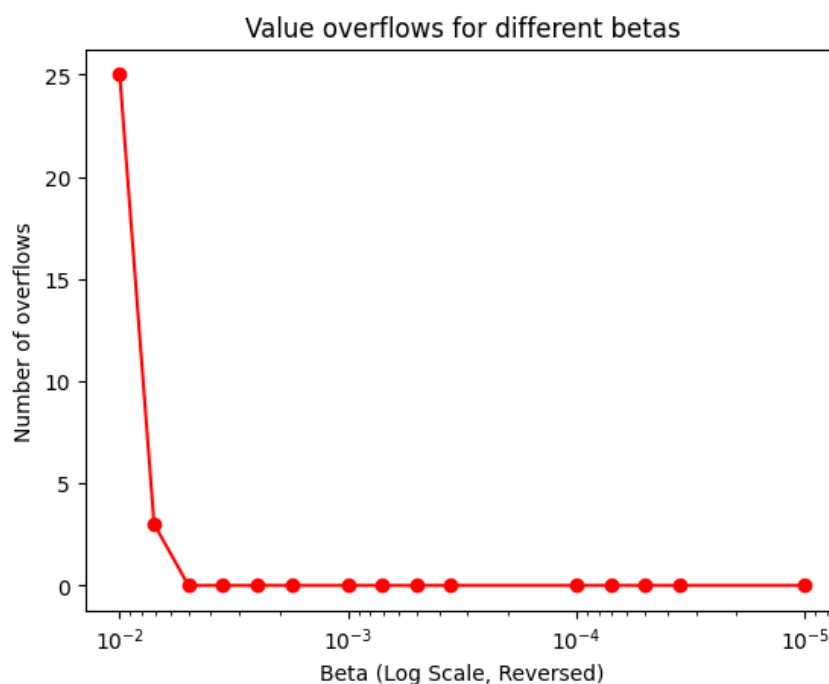
- $\beta$  – parametr reprezentujący wielkość kroku
- $\epsilon$  – (ustawiono na  $10^{-9}$ ) maksymalna różnica w pozycji pomiędzy kolejnymi iteracjami przy której algorytm kończy pracę.
- $\max\_iter$  – (ustawiono na 10000) maksymalna ilość iteracji jaką może wykonać algorytm.

Wykonano badanie polegające na wybraniu kilku parametrów  $\beta$  (kroku), i dla każdego z nich sprawdzono wyniki działania algorytmu na 50 losowo wybranych punktach w rozsądnych granicach dziedziny funkcji. W ten sposób będzie można wybrać optymalny krok dla funkcji.

## Statystyki dla funkcji $f(x)$

### 1. Zbieżność algorytmu

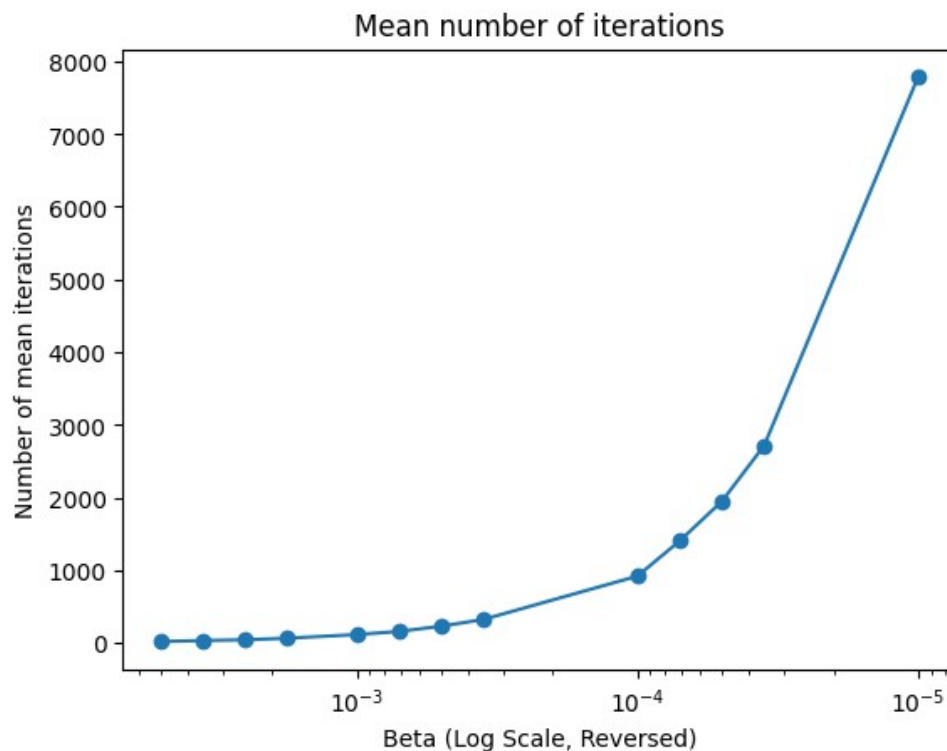
Jeżeli krok był ustawiony na zbyt duży algorytm wpadał w oscylacje i nsatępowało przepełnienie zmiennych. Zawężono obszar poszukiwań wartości bety eliminując takie przypadki.



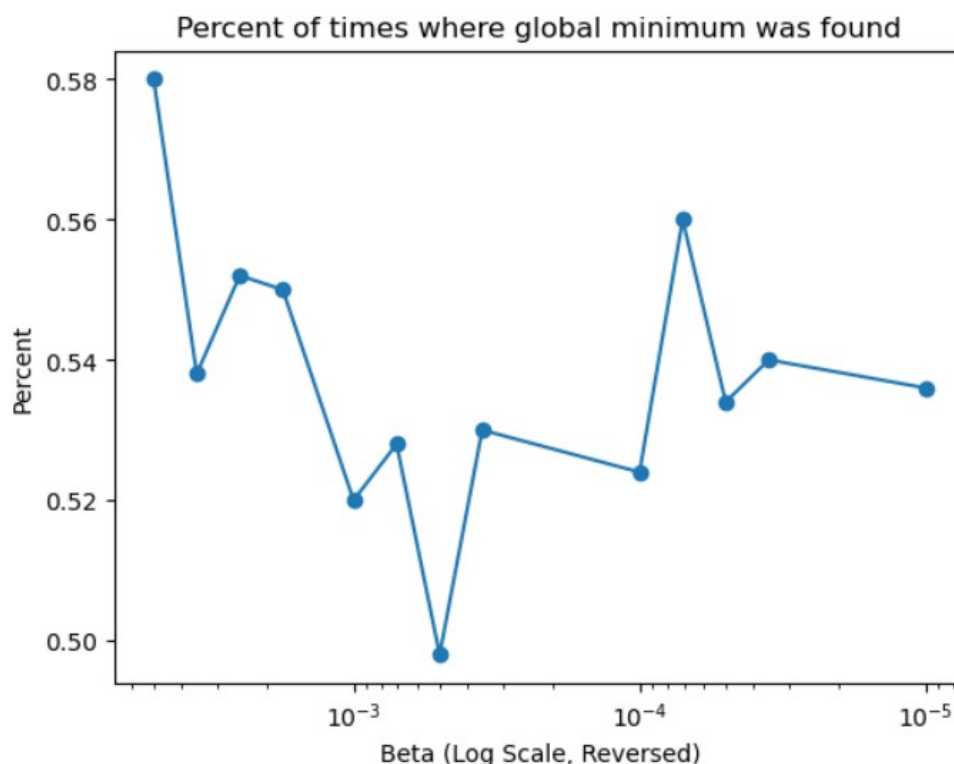
Dla wybranych granic funkcji  $f(x)$  algorytm nie jest zbieżny dla wszystkich przypadkowo wybranych wartości  $\beta$

### 2. Średnia ilość iteracji algorytmu

Zmniejszanie kroku zwiększa ilość iteracji jaką musi wykonać algorytm.



Ponieważ funkcja  $f(x)$  ma bardzo blisko siebie minimum lokalne i globalne bardzo często zostało znajdowane niewłaściwe minimum. Postanowiono więc wyznaczyć zależność częstości znajdowania właściwego minimum od bety dla bardzo dużej liczby losowych punktów  $n=500$ .




Jak widać w każdym przypadku poprawność rozwiązania jest niewiele większa niż 50% (bo 2 minima). Pokazuje to, że istotnym jest wykonanie wielu testów dla losowych punktów i wybranie najmniejszego rozwiązania. Po wykonaniu wielu testów widać jednak większą

powtarzalność poprawnych rozwiązań dla większych dużych kroków. Kroki te częściej pomijają minimum lokalne i wpadają w globalne.

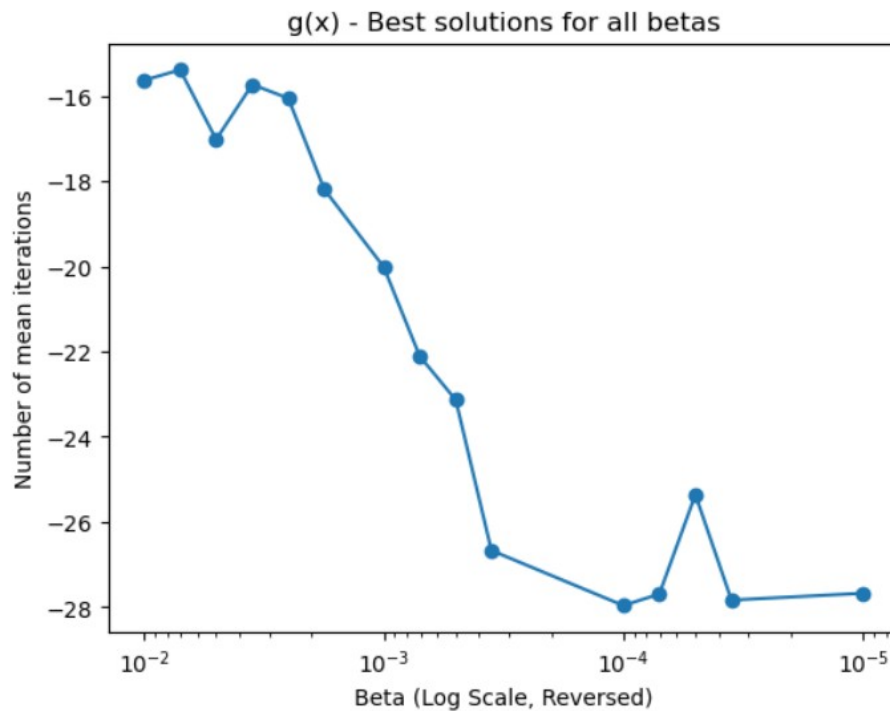
## Statystyki dla funkcji $g(x)$

### 1. Zbieżność algorytmu



Jak widać algorytm jest zbieżny dopiero dla dużo mniejszych współczynników  $\beta$ , Jest to jednak tak zależne od samej funkcji jak i od przyjętych granic punktów początkowych.

## 2. Wartość najlepszego z rozwiązań dla każdego z współczynników beta



Widać że dostajemy lepsze rozwiązania im mniejszy krok, lecz zależność ta wypłaszcza się dla bardzo małych współczynników beta ze względu na płaskość w minimum samej funkcji.

## 3. Liczba Iteracji

